



بازیابی افزوده مبتنی بر دانش برای وظایف پردازش زبان طبیعی

دانشگاه تربیت مدرس - دانشکده مهندسی برق و کامپیوتر

ارائه و بررسی مقاله:

Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks

استاد:

سرکار خانم دکتر مهدیه قاسمی
ارائه‌دهندگان:

راشد شهابی - معصومه مختاری



کتابخانه عصبی: تکامل هوش مصنوعی با تولید افزوده شده با بازیابی بازیابی (RAG)

رویکردی نوین برای وظایف پردازش زبان
طبیعی مبتنی بر دانش عمیق



انجماد دانش: مدل‌های زبانی در زمان آموزش متوقف می‌شوند. آن‌ها نمی‌توانند رویدادهای جدید را درک کنند.



توهم: در غیاب دسترسی به حقایق، مدل‌ها با اعتماد به نفس کامل اطلاعات غلط تولید می‌کنند.




فقدان شفافیت: وقتی مدل پاسخی می‌دهد، نمی‌توانیم منبع یا مرجع آن تصمیم را ردیابی کنیم.



مدل‌های پارامتریک به تنهایی نمی‌توانند وظایف نیازمند به دانش دقیق را با اطمینان انجام دهند.

پارادایم شیف: پیوند حافظه پارامتریک و غیرپارامتریک

مدل (Retrieval-Augmented
Augmented Generation)
یا RAG چگونه کار می‌کند؟



حافظه غیرپارامتریک

مانند ویکی‌پدیا دسامبر ۲۰۱۸ با ۲۱
۲۱ میلیون سند متنی متراکم.
وظیفه: ارائه حقایق تغییرپذیر و دقیق.

حافظه پارامتریک


مانند شبکه عصبی BART با ۴۰۰ میلیون پارامتر.
وظیفه: درک زبان، گرامر، و تولید متن روان.

هوش مصنوعی دیگر نیازی به حفظ کردن تمام دنیا
ندارد؛ فقط باید یاد بگیرد چگونه آن را بخواند.


مقایسه معماری‌های پاسخ‌گویی به سوالات (QA)

ویژگی‌ها	کتاب‌بسته (T5/BART)	استخراجی (DPR)	هیبریدی (RAG)
منبع دانش	فقط پارامتریک	فقط غیرپارامتریک	هیبریدی ترکیبی
تولید متن آزاد	عالی	ضعیف (کپی‌پیست)	عالی
خطر توهم	بسیار بالا	پایین	بسیار پایین
قابلیت بروزرسانی	غیرممکن	آسان	آسان با تعویض شاخص

کالبدشکافی معماری RAG




دو رویکرد در تولید متن: RAG-Sequence در برابر RAG-Token



رویکرد RAG-Token: بافت‌سازی پویا.

مدل می‌تواند برای تولید هر کلمه، از سند متفاوتی استفاده کند.
(مناسب برای پاسخ‌های طولانی و ترکیبی).



رویکرد RAG-Sequence: حاکمیت یک سند بر کل پاسخ.

مدل یک سند واحد را انتخاب کرده و کل توالی کلمات را بر اساس همان سند تولید می‌کند.
(مناسب برای پاسخ‌های کوتاه).

جادوی RAG-Token: ترکیب حقایق در لحظه

درخواست تولید سوال برای کلمه کلیدی همی‌نگوی



مدل‌های RAG-Token دانش استخراج شده از چندین سند مختلف را در یک جمله روان و واحد ترکیب می‌کنند.

برتری مطلق در پاسخ‌گویی به سوالات باز (Open-Domain QA)



مدل RAG بدون نیاز به پیش‌آموزش‌های گران‌قیمت، به رکورد جدیدی (SotA) دست یافت و معماری‌های پیشین را پشت سر گذاشت.

فراتر از کپی‌پیست: تولید متن خلاقانه و مبتنی بر واقعیت

ارزیابی انسانی در تولید سوالات مسابقه

۴۲.۷% ۷.۱%

درصد مواقعی که متن تولید شده توسط RAG از نظر واقعیت بهتر از BART بود.

درصد مواقعی که BART بهتر عمل کرد.

برخلاف مدل‌های استخراجی، RAG می‌تواند مفاهیم را استنتاج کرده و پاسخ‌هایی دقیق تولید کند، حتی زمانی که پاسخ کلمه‌به‌کلمه در هیچ سندی وجود نداشته باشد.

تعویض حافظه در حال اجرا (Hot-Swapping)

تست مدل با رهبران جهان:

با شاخص ۲۰۱۶:

پاسخگویی صحیح به ۷۰٪
از سوالات سال ۲۰۱۶

با شاخص ۲۰۱۸:

پاسخگویی صحیح به ۶۸٪
از سوالات سال ۲۰۱۸
(بدون هیچگونه آموزش مجدد)



به روزرسانی درک مدل از جهان، تنها با جایگزینی پایگاه داده غیرپارامتریک، بدون نیاز به حتی یک مرحله آموزش اضافی انجام می‌شود.

آینده هوش مصنوعی: پایان عصر حفظ کردن



با معماری RAG، ما در حال گذار از یک هوش مصنوعی استاتیک، کدر و شکننده به یک هوش مصنوعی پویا، قابل تفسیر و مبتنی بر واقعیت هستیم.

همافزایی

پیوند بی نقص مهارت زبانی و دقت اطلاعاتی.

پویایی

دانش جهان به سرعت تغییر می کند؛ پایگاه داده هوش مصنوعی نیز باید چنین باشد.

تفسیرپذیری

اسناد خروجی قابلیت خوانش و بررسی توسط انسان را دارند.